

RINGKASAN DATA & MODEL



768

baris · 9 kolom
DATASET AWAL

768

baris terproses
DATA TERVALIDASI

376

baris terimputasi
IMPUTASI NOL KLINIS

24

fitur klinis
FITUR FINAL

80/20

rasio stratified
SPLIT TRAIN/TEST

75,32%

Accuracy (LightGBM)
MODEL TERBAIK

TEKNIK INTI

KNN Imputer (k=5)

16 Composite Features

SMOTE Resampling

Optuna Bayesian Tuning

XGBoost

LightGBM

Random Forest

ALUR KERJA EKSPERIMEN

01

J. 62DMI00.001.1
Objektif Bisnis

- Skrining Cepat:** Deteksi dini risiko diabetes biner.
- Intervensi Dini:** Pencegahan sebelum komplikasi.
- Efisiensi Biaya:** Menekan biaya perawatan.

02

J. 62DMI00.002.1
Tujuan Teknis

Klasifikasi biner target 0/1, fokus pada **Accuracy & ROC-AUC**, serta fitur klinis penting.

03

J. 62DMI00.005.1
Menelaah Data

Analisis **768 baris & 9 kolom** Pima Indians Dataset, dengan 0 tidak logis pada glucose, bp, skin, insulin, bmi.

04

J. 62DMI00.006.1
Memvalidasi Data

Cek konsistensi data klinis, mengidentifikasi 0 tidak logis sebagai missing values yang memerlukan imputasi.

05

J. 62DMI00.007.1
Menentukan Objek Data

X = 8 fitur klinis sebelum rekayasa; y = target diabetes (0 = sehat, 1 = diabetes).

06

J. 62DMI00.008.1
Membersihkan Data

Mengganti nilai 0 tidak logis dengan **KNN Imputer (k=5)** secara legal di dalam pipeline lipatan CV untuk mencegah target leakage.

07

J. 62DMI00.009.1
Mengkonstruksi Data

Membuat **16 fitur komposit klinis baru** dan standarisasi yang diterapkan per lipatan CV di Skenario 3.

08

J. 62DMI00.012.1
Membangun Skenario Model

Skema **Stratified 5-Fold CV** dengan penyeimbangan kelas dan **Optuna Bayesian Tuning** secara terisolasi per lipatan training.

09

J. 62DMI00.013.1
Membangun Model

Melatih model akhir **LightGBM (Optimized)** memakai hyperparameter terbaik hasil tuning Optuna pada Skenario 3.

10

J. 62DMI00.014.1
Mengevaluasi Model

Mengevaluasi performa final Skenario 3 (LightGBM) pada test set, mencapai **75,32% Accuracy** dan **81,70% ROC-AUC**.

11

J. 62DMI00.015.1
Review Pemodelan

Mengonfirmasi keberhasilan Skenario 3 yang bebas dari efek *target leakage* semu seperti pada Skenario 2 (Akurasi 90,50%).

HASIL PERFORMA EKSPERIMEN NOTEBOOK (4 MODEL)

MODEL	SKENARIO 1 (SPLIT-FIRST) ACCURACY AUC		SKENARIO 2 (LEAKAGE) ACCURACY AUC		SKENARIO 3 (OPTIMIZED) ACCURACY AUC	
LightGBM	73.38%	80.19%	90.50%	96.44%	75.32%	81.70%
XGBoost	72.08%	80.76%	89.50%	95.95%	72.08%	80.76%
Gradient Boosting	72.08%	81.06%	90.50%	96.86%	72.08%	81.06%
Random Forest	69.48%	79.31%	91.00%	96.84%	69.48%	79.31%

PERBANDINGAN PERFORMA EKSPERIMEN (ACCURACY)

EKSPERIMEN 01

Split-First (Baseline)
73,38%

EKSPERIMEN 02

Preprocess-First (Leakage)
90,50%

EKSPERIMEN 03

LightGBM (Optimized)
75,32% ★ BEST

ANALISIS FITUR & EVALUASI KLINIS

TOP 4 FITUR TERPENTING (FEATURE IMPORTANCE)

Glucose	32%
BMI	24%
Age	18%
GlucxBMI	14%

FOKUS METRIK KLINIS (SKENARIO 3)

74,07%
RECALLSensitivitas tinggi meminimalkan pasien diabetes terlewat (*False Negative*), sangat vital untuk penapisan awal medis.

TEMUAN UTAMA & ANALISIS EKSPERIMEN



Sebanyak **376 baris data** memiliki nilai 0 tidak logis pada fitur vital, memerlukan *class-conditional imputation* agar model tidak bias.



Eksperimen 2 membuktikan *target leakage* mendongkrak performa semu hingga **96,86% ROC-AUC**, yang berbahaya untuk diagnosis klinis.



Tuning Optuna pada **LightGBM** bebas leakage berhasil mencapai **75,32% Accuracy** secara valid untuk deployment nyata.