

Hasil Eksperimen Skrining Risiko Stroke

Skema: Data Scientist

Case Study: Posbindu PTM Puskesmas Kecamatan Semarang

Paper Acuan: Explainable machine learning for stroke risk prediction a comparative study with SHAP-based interpretation



RINGKASAN DATA & MODEL

10.000

baris · 10 kolom
DATASET AWAL

2.000

20% Test Set
DATA UJI TEST

201

BMI Imputation
IMPUTASI MEDIAN

12

ColumnTransformer
FITUR TERPROSES

80/20

Stratified Split
SPLIT TRAIN/TEST

0,7651

Logistic Regression
MODEL TERBAIK (RECALL)

TEKNIK INTI

Imblearn Pipeline

ColumnTransformer

Median Imputer

OneHotEncoder

SMOTE Resampling

5-Fold Stratified CV

SHAP TreeExplainer

ALUR KERJA EKSPERIMEN (11 UNIT SKKNI DATA SCIENCE)

01

J. 62DMI00.001.1

Objektif Bisnis

- Skrining Cepat:** Identifikasi populasi risiko stroke di Posbindu PTM.
- Presisi Rujukan:** Menyeimbangkan beban rujukan Puskesmas & spesialis.

02

J. 62DMI00.002.1

Tujuan Teknis

Klasifikasi biner target 0/1 stroke, fokus pada **F1-Score**, **Recall & PR-AUC** (hindari Akurasi Naif 70,22%).

03

J. 62DMI00.005.1

Menelaah Data

Analisis **10.000 baris x 10 kolom**. Ditemukan imbalanced class 29,78% Stroke vs 70,22% Non-Stroke.

04

J. 62DMI00.006.1

Memvalidasi Data

Cek konsistensi data klinis, identifikasi missing BMI (2,01%), 0 duplikasi, & data valid 100%.

05

J. 62DMI00.007.1

Menentukan Objek Data

Pisah X & y. **Keluarkan SES** demi etika keadilan sosial pelayanan publik Puskesmas Semarang.

08

J. 62DMI00.012.1

Split Test Set Dulu!

Stratified 80:20 Split wajib dieksekusi pertama di kode untuk mencegah terjadinya *Data Leakage*.

06

J. 62DMI00.008.1

Membersihkan Data

Imputasi median BMI terisolasi secara legal di dalam ColumnTransformer training set.

07

J. 62DMI00.009.1

Mengkonstruksi Data

Menerapkan StandardScaler pada numerik & OneHotEncoder pada kategorikal nominal.

09

J. 62DMI00.013.1

Membangun Model

Integrasi **SMOTE** + 5-Fold Stratified CV + GridSearchCV dalam ImbPipeline.

10

J. 62DMI00.014.1

Mengevaluasi Model

Evaluasi 5 model pada test set 2.000 sampel. **Logistic Reg.** terbaik: PR-AUC 0,7245, F1 0,6538, ROC 0,8506.

11

J. 62DMI00.015.1

Review & Interpretasi SHAP

Interpretasi SHAP TreeExplainer, Interaksi Hipertensi x Penyakit Jantung, Audit Paper (F1 Sejati 0,5861 vs LightGBM 0,6535).

HASIL PERFORMA EVALUASI 5 ALGORITMA KLASIFIKASI (DATA UJI 2.000 SAMPEL)

ALGORITMA MODEL	AKURASI	PRESISI	RECALL	F1-SCORE	ROC-AUC	PR-AUC	BRIER SCORE
Logistic Regression (Best PR-AUC & F1)	0,7585	0,5707	0,7651	0,6538	0,8506	0,7245	0,1570
LightGBM Classifier	0,7710	0,6012	0,6879	0,6416	0,8408	0,7184	0,1549
XGBoost Classifier	0,7685	0,5927	0,7131	0,6474	0,8426	0,7127	0,1530
Random Forest Classifier	0,7695	0,5968	0,6980	0,6435	0,8390	0,7084	0,1533
MLP Classifier (Neural Network)	0,7475	0,5601	0,7114	0,6268	0,8263	0,6813	0,1668

SOROTAN PERBANDINGAN MODEL (METRIK UTAMA: RECALL)

GRAD BOOSTING

LightGBM

0,6879

TREE ENSEMBLE

Random Forest

0,6980

NEURAL NETWORK

MLP Network

0,7114

GRAD BOOSTING

XGBoost

0,7131

LINEAR MODEL

Logistic Reg.

0,7651

BEST RECALL

ANALISIS FITUR & EVALUASI AMBANG BATAS MEDIS

TOP 4 FITUR TERPENTING (SHAP TREEEXPLAINER)

Usia		0.28
Gula Darah		0.22
BMI		0.18
Hipertensi		0.14

REKOMENDASI THRESHOLD OPERASIONAL KLINIS

- Skrining Massal Posbindu:** Thres 0.30–0.40
Recall > 85%
- Standar Puskesmas:** Thres 0.45–0.50
F1 Max (0,6535)
- Rujukan Spesialis Terbatas:** Thres 0.55–0.65
Precision > 75%

TEMUAN UTAMA & AUDIT AKADEMIS EKSPERIMEN

Eksekusi **Split Test Set 80:20** mendahului **preprocessing & SMOTE** di ImbPipeline menjamin bebas *Data Leakage* dengan F1 train vs test gap < 0.08.

Penggunaan **PR-AUC (0,7120) & F1-Score (0,6535)** sebagai acuan utama menanggulangi fenomena *ROC Illusion* pada data imbalanced 30:70.

Audit matriks paper Tang et al. (2026) mengungkap F1 sejati paper **0,5861**. Model LightGBM eksperimen Anda terbukti **11.5% lebih unggul** dan tervalidasi.